

Projektauftrag

Modul Datenbanksysteme (DBS)


Ziel: Sie arbeiten während des Semesters an einem Datenbankprojekt in Teams von 4 Personen. Setzen Sie das Projekt mit Datenbanktechnologien um. Wir arbeiten mit MySQL als SQL-Datenbank und mit MongoDB als NoSQL-Datenbank. Als BI-Tool setzen wir Metabase ein. Diese Systeme installieren Sie auf der Virtual Machine (VM), die im Unterricht zur Verfügung gestellt wird.

Vorgehen:

- 1.) Datenbankanwendung planen
- 2.) Datenbankstruktur definieren (SQL)
- 3.) Daten laden & transformieren (SQL)
- 4.) Datenbank analysieren (SQL)
- 5.) Datenbank-Performance optimieren (SQL)
- 6.) Resultate visualisieren und anwenden (SQL)
- 7.) Datenbankstruktur definieren (NoSQL)
- 8.) Daten laden & transformieren (NoSQL)
- 9.) Datenbank analysieren (NoSQL)
- 10.) Datenbank-Performance optimieren (NoSQL)
- 11.) Resultate visualisieren und anwenden (NoSQL)
- 12.) Projektbericht schreiben

1. Datenbankanwendung planen

- Entwickeln Sie die Ideen für Ihr Projekt mit je einer SQL- und einer NoSQL-Datenbank.
- Die Datenanalyse in Ihrem Projekt soll eine **Entscheidungsfindung** unterstützen und somit mit Daten einen Wert schaffen, analog zum Data Value Cycle (OECD, 2015).



- Spezifizieren Sie, welche **Kennzahlen** aufgrund welcher Daten ermittelt werden können.
- Geben Sie die **Entscheidungsregeln** an, wie die datenbasierte Entscheidungsfindung den Anwendungsfall unterstützt.
- Wählen Sie die Daten aus, die den Entscheidungsträgern im Anwendungsfall helfen können. Kombinieren Sie **mindestens zwei** verschiedene, formal, strukturell und inhaltlich unabhängige Datenquellen.
- Eine Auswahl von möglichen Datenquellen finden Sie im Anhang.

2. Datenbankstruktur definieren

- Da Sie mit vorhandenen Daten arbeiten, müssen Sie das konzeptionelle Modell anhand der bereits vorhandenen Daten zurückentwickeln.
- Analysieren Sie Struktur und Inhalt der Quelldaten anhand von Datenbeispielen.
- Überlegen Sie, wie das konzeptionelle ER-Modell aufgrund der Quelldaten aussehen könnte, und modellieren Sie dieses. Mit anderen Worten: Sie müssen das konzeptionelle Modell der vorhandenen fachlichen Entitäten, Attribute und Beziehungen aus den Quelldaten extrahieren und über die verschiedenen Quellen integrieren.
- Erstellen Sie ein konzeptionelles, graphisches Modell, welches die fachlichen Entitäten, Beziehungen und Attribute in den Quelldaten abbildet. Wir erwarten mehrere Entitätstypen und Beziehungen mit jeweils qualitativen Attributen, sowie detaillierte Beschreibungen.
- Der nächste Schritt ist, die Datenstruktur in der SQL- und in der NoSQL-Datenbank als physisches Schema (SQL DDL / JSON Prototyp) zu implementieren. Das effektive Schema im DBMS kann vom konzeptionellen Modell begründet abweichen.
- Das Datenbankschema der SQL-DB muss in dritter Normalform sein. Das Datenbankschema der NoSQL-DB muss mind. teilweise aggregiert sein, d.h. denormalisiert oder ohne Normalform.
- Zeigen Sie auch den Zusammenhang zwischen konzeptionellem Modell und dem Datenbankschema auf.
- Zusätzlich zum Modell und zum Schema sollten Sie die wichtigsten Daten, die für die Transformation, Analyse, Visualisierung und Entscheidungsfindung wesentlich sind, auch in Prosa beschreiben.

3. Daten laden & transformieren

- Installieren Sie zwei Datenbankserver: Je ein MySQL- und ein MongoDB-Datenbanksystem mit Client-Server Architektur (Server in der Cloud oder VM auf Lab-Services HSLU). Wichtig ist, dass Ihr Datenbanksystem online implementiert wird, so dass die Bewertenden sich einloggen können, um Ihre Arbeit nachzuvollziehen. Sie müssen also die Zugangsdaten für die Bewertung auf ILIAS offenlegen. Dazu gibt es eine Umfrage mit Text-Input im Ordner Projekt.
- Verwenden Sie den ELT-Ansatz: Importieren Sie erst die Daten in Ihre Datenbank. Für MySQL verwenden Sie den LOAD Befehl (oder mysqlsh), da dies sehr leistungsfähig ist. Für MongoDB verwenden Sie mongoimport.
- Sie sollen nach dem ELT-Prinzip die Daten innerhalb der Datenbank mit den Funktionen des Datenbankservers transformieren. In SQL können Sie Daten mit der INSERT ... SELECT Anweisung transformieren. In MongoDB verwenden Sie Aggregation Pipelines (\$out, \$merge).
- Preprocessing ist möglich, solange die Mehrheit der Transformation im Datenbankserver erfolgt.

4. Datenbank Analysieren

- Schreiben Sie für die SQL-Datenbank und für die NoSQL-Datenbank je mindestens eine Datenbank-Abfrage für Ihren Anwendungsfall, um Erkenntnisse für die Entscheidungsfindung zu gewinnen
- Die SQL-Abfrage sollte mindestens 15+ verschiedene Keywords enthalten. Z.B.:
 - Tabellen verbinden (JOIN)
 - Verarbeitung der Wertemengen zu einem einzigen Wert (Aggregation, z.B. AVG)
 - Gruppierung von Aggregaten nach Dimensionen (GROUP BY)
 - Filtern von Datensätzen (WHERE)
 - Auswahl von Attributen (SELECT)
 - Usw.
- Die MongoDB-Abfrage sollte mindestens 15+ verschiedene Keywords enthalten. Z.B.:
 - Collections verbinden (\$lookup)
 - Verarbeitung der Wertemengen zu einem einzigen Wert (Akkumulator, z.B. \$sum)
 - Gruppierung von Aggregaten nach Dimensionen (\$group)
 - Filtern von Datensätzen (\$match)
 - Auswahl von Attributen (\$project)
 - Usw.
- Beschreiben sie wörtlich, was Ihre Datenbankabfragen machen, und wie sie genau funktionieren. Zeigen Sie auf, wie sie die Kennzahlen, die Sie unter Punkt 1 definiert haben, mit dieser Datenbankabfrage berechnen können.
- Zeigen Sie die Resultate der Abfragen auf, und diskutieren sie, wie die Resultate den Use Case unterstützen. Die Resultate sollten bei SQL und NoSQL gleich sein.

5. Datenbank-Performance optimieren

- Zeigen Sie für SQL und für NoSQL auf, welche Massnahmen Sie für die Optimierung der Abfragegeschwindigkeit vornehmen.
- Optimierungsmassnahmen: Analyse Ausführungsplan, Indexe, Materialized Views
- Sammeln Sie Daten, um nachzuweisen, dass die Optimierung funktioniert: Messen Sie Laufzeiten vor und nach der Optimierung.

6. Resultate visualisieren und anwenden

- Installieren Sie das BI-Tool (Metabase) und verbinden Sie es mit beiden Datenbanken. Zeigen Sie die Konfiguration auf, die Sie anwenden.
- Stellen Sie die Analyseergebnisse mittels Datenbank-Query sowohl für MySQL als auch für MongoDB im BI-Tool interaktiv, d.h. mit Parametern, grafisch dar, so dass sie bei der Entscheidungsfindung optimal genutzt werden können.
- Zeigen Sie, wie ein Benutzer interaktiv mit der Visualisierung der SQL- und der NoSQL-Abfragen arbeiten kann.
- Zeigen Sie, dass der Output der SQL- und der NoSQL Abfrage und Visualisierung gleich ist.
- Zeigen Sie ganz praktisch auf, wie die Visualisierung und ursprünglicher Use Case zusammenhängen: Spielen Sie anhand eines Benutzers durch, wie die Visualisierung eine bestimmte Entscheidung mit Daten verbessert.
- Geben Sie auf der Grundlage der Kennzahlen eine Empfehlung für eine beispielhafte datengestützte Entscheidung für den Use Case ab.

7. Projektbericht schreiben

- Schreiben Sie einen technischen Bericht über Ihr Projekt.
- Achten Sie darauf, dass Sie auf der Titelseite die **Namen und E-Mail-Adressen** der Autoren, den **Namen des Teams** und den **Titel Ihres Projekts** angeben. Das Titelblatt gilt als verbindliche Bestätigung, dass alle Teammitglieder zu allen Projektteilen einen Beitrag geleistet haben und deshalb mit einer gemeinsamen Team-Note einverstanden sind.
- Maximale Länge: max. **80 Seiten** (exkl. Titelblatt, Inhaltsverzeichnis, Anhang).
- Abschließend geben Sie auch eine Reflexion und Lessons Learned zu den Themen Datenbanktechnologie, Projektmanagement, Zusammenarbeit im Team, sowie Einsatz von künstlicher Intelligenz. Ziel ist, zu beschreiben, wie sie es in diesen Themen aufgrund der im Projekt gewonnenen Erkenntnisse nächstes Mal besser machen können. Erklären Sie dies anhand ganz konkreter Lektionen, die sie im Projekt aufgrund konkreter Situationen gelernt haben.
- Alle verwendeten KI-Tools und deren Einsatzzwecke müssen in den Lessons learned klar offengelegt werden.
- Struktur: Es gibt je ein Kapitel pro Kriterium 1-7. Alle zu bewertenden Ergebnisse zu einem Kriterium befinden sich im entsprechenden Kapitel (keine Querverweise auf andere Kapitel oder Anhänge)
- Erstellen Sie eine PDF-Datei (kein Zip etc.) mit Ihrem Bericht. Es wird ausschliesslich der Inhalt in der einen PDF-Datei Ihres Projektberichts für die Bewertung (exkl. Anhang) berücksichtigt.
- Laden Sie die PDF-Datei im Abgabeorder auf ILIAS hoch. Eine Abgabe pro Team reicht. Bei mehreren Abgaben wird die Abgabe der ersten Person in alphabetischer Reihenfolge bewertet.
- **Abgabe: Final Submission.** Am Semesterende reichen Sie den endgültigen Stand des Projekts rechtzeitig ein, der für die Modulnote zählt.

8. Administratives

- Der schriftliche Bericht im PDF-Format, und nur dieser, anhand der im Projektauftrag festgelegten Kriterien bewertet.
- In der Regel arbeiten vier Studierende an einem Projekt gemeinsam bei allen Projektteilen mit (Teambewertung). Falls dies nicht möglich ist, oder falls keine Einigung zustande kommt, könnten auch Dreierteams, Zweierteams oder Einzelpersonen ein Projekt bearbeiten. Der Umfang des Projekts bleibt jedoch gleich.
- Bei Team-Konflikten ist so rasch wie möglich ein Gespräch des ganzen Teams mit dem Dozenten zu organisieren.
- Wenn ein Team aufgeteilt werden muss, können alle ehemaligen Mitglieder ausschliesslich über die von Ihnen selbstständig erstellten Resultate bis zum Aufteilen des Teams verfügen. Über recherchierte öffentliche Informationen (Publikationen, Datensätze, Tools usw.) dürfen sämtliche Mitglieder verfügen, solange diese korrekt referenziert werden.
- Repetierende müssen ein komplett neues Projekt mit einem vollständig neuen Team erarbeiten.

9. Bewertungskriterien und Erwartungen

Ihre Projektarbeit wird anhand folgender Kriterien bewertet.

1 Projektidee:

- Der Use Case ist relevant und kohärent.
- Die Entscheidungsunterstützung basiert auf einer klaren Entscheidungsregel mit mathematisch definierter, zu berechnender Kennzahl.

- Es werden 2+ unabhängige, aber integrierbare Datenquellen beschrieben und referenziert, welche den Use Case ermöglichen und für den Use Case auch notwendig sind.

2 Datenmodell:

- Die Quelldatenanalyse zeigt Struktur und Inhalt der Daten anhand konkreter Beispiele auf
- Das konzeptionelle Modell erklärt die wesentlichen Entitäten, Beziehungen und Attribute der Zieldatenstruktur graphisch und korrekt über alle Quellen integriert als ER-Diagramm (MySQL) bzw. als ER-Dokument-Diagramm (MongoDB)
- Das Datenbankschema in DDL definiert die Struktur der Datenbank inkl. korrekter Datentypen, Primär- und Fremdschlüssel in dritter Normalform in SQL; sowie syntaktisch und semantisch korrekte, denormalisierte und aggregierte JSON-Prototypen für MongoDB.

3 Loading & Transformation:

- Die Ladeprozesse sind nachvollziehbar und performant mit MySQL LOAD; bzw. mit mongoimport
- Die Transformationen der Daten ins Zielschema werden nach ELT sinnvoll und skalierbar in SQL bzw. in MQL umgesetzt

4 Analytics:

- Die SQL-Query und die MQL-Query berechnen eine aggregierte Kennzahl und haben eine angemessene Komplexität mit 15+ Keywords
- Das Resultat bezieht sich direkt auf den Use Case, indem es die Kennzahl für die Entscheidungsregel bereitstellt.

5 Optimierung:

- Die Performance-Optimierung verwendet 3+ Datenbank-Ansätze, um die Ausführungsgeschwindigkeit zu erhöhen; inkl. Execution Plan, Indexierung, Materialized Views; sowohl in SQL als auch in MQL.
- Die Ausführungsgeschwindigkeit ist nach der Optimierung messbar schneller.

6 Visualisierung:

- Das interaktive BI-Dashboard in Metabase stellt die Kennzahl aufgrund der Berechnung in den beiden Datenbank-Systemen graphisch und parametrisiert dar; mit SQL und MongoDB stimmen die Kennzahlen überein.
- Die Entscheidungsregel wird exemplarisch aufgrund der Kennzahl für einen (fiktiven) Benutzer angewandt, um eine Entscheidung im Use Case positiv zu beeinflussen.

7 Lessons Learned:

- Arbeit mit Datenbanken: 1+ Projektsituation mit Erkenntnis
- Projektorganisation: 1+ Projektsituation mit Erkenntnis
- Teamarbeit: 1+ Projektsituation mit Erkenntnis
- Einsatz von künstlicher Intelligenz in Projektarbeiten: 1+ Projektsituation mit Erkenntnis; Alle verwendeten KI-Tools und ihren Einsatzbereich werden klar offengelegt.

8 Projektbericht:

- Die formalen Kriterien (siehe Kapitel 7, Projektbericht schreiben) wurden eingehalten
- Der Projektbericht ist sinnvoll strukturiert, verständlich geschrieben und professionell dargestellt.

9 Zwischenpräsentation:

- Die Inhaltlichen Kriterien zur Projektidee (siehe Kriterium 1) werden erfüllt
- Die Inhaltlichen Kriterien zum entsprechenden Präsentationsthema werden erfüllt
- Die Präsentation ist formal korrekt (pünktlich, vor Ort, alle Teammitglieder sprechen, mit Zoom, Screenshare, Kamera)

10. Mögliche Punkte pro Kriterium

Pro Kriterium Projektidee bis Projektbericht oben, werden mit je 0 bis 3 Punkte erteilt, anhand folgender Bewertungslogik:

- 3 Punkte: Die Erwartungen wurden erfüllt
- 2 Punkte: Die Erwartungen wurden mehrheitlich erfüllt
- 1 Punkt: Die Erwartungen wurden teilweise erfüllt
- 0 Punkte: Die Erwartungen wurden nicht erfüllt

Wichtiger Hinweis: Die Erwartungen pro Kriterium können nur erfüllt werden, wenn die folgenden Leistungsnachweise wo möglich erbracht werden:

- *Überprüfbares Online-System:* alle Resultate sind, wo immer möglich auf einem über Internet oder Intranet zugreifbaren Datenbanksystem implementiert. Geben Sie auf ILIAS in der Umfrage im Ordner "Informationen zum Modul / Projekt" die Zugangsinformationen (URL, Benutzer, Passwort und ggf. weitere Parameter) für VM, MySQL, MongoDB und Metabase im Abschnitt über die Systemarchitektur an, damit bei der Bewertung die Implementierung überprüft werden kann.
- *Code:* Alle Resultate sind, wo immer möglich, mit vollständigem lauffähigem Datenbank-Code belegt!
- *Screenshots:* Die Umsetzung auf der Datenbank ist wo immer möglich mit Bildschirmfotos der Resultate der Codeausführung im Report belegt.
- *Struktur:* Es gibt je ein Kapitel pro Kriterium 1-8. Alle zu bewertenden Ergebnisse zu einem Kriterium befinden sich im entsprechenden Kapitel (keine Querverweise auf andere Kapitel oder Anhänge)
- *Beschreibung:* Alle Resultate zusammen mit den Lösungswegen zur Erreichung der Resultate sind verständlich in Prosa beschrieben. Es ist also nicht nur wichtig was das Resultat ist, sondern auch, wie sie darauf gekommen sind.

11. Mögliche Datenquellen (validiert)

7k Books with Metadata

<https://www.kaggle.com/dylanjcastillo/7k-books-with-metadata>

Amazon Books Reviews

<https://www.kaggle.com/mohamedbakhet/amazon-books-reviews>

Anime Dataset 2023

<https://www.kaggle.com/dataset/dbdmobile/myanimelist-dataset>

Anzahl Straftaten nach Tatbestandsgruppe für ausgewählte Gemeinden und die Stadtkreise der Stadt Zürich, seit 2009

https://data.stadt-zuerich.ch/dataset/ktzh_pks_straftaten_tatbestandgruppe_gemeinden_stadtkreise

Bevölkerung nach Monat, Stadtquartier, Geschlecht, Altersgruppe und Herkunft

https://data.stadt-zuerich.ch/dataset/bev_monat_bestand_quartier_geschl_ag_herkunft_od3250

Book-Crossing: User review ratings

<https://www.kaggle.com/datasets/ruchi798/bookcrossing-dataset>

Breached_dataset

<https://www.kaggle.com/datasets/dannyduncan/breached-dataset>

Common Password List (rockyou.txt)

<https://www.kaggle.com/datasets/wjburns/common-password-list-rockyoutxt>

Daten der Verkehrszählung zum motorisierten Individualverkehr (Stundenwerte), seit 2012

https://data.stadt-zuerich.ch/dataset/sid_dav_verkehrszaehlung_miv_od2031

Food.com - Recipes and Reviews

<https://www.kaggle.com/datasets/irkaal/foodcom-recipes-and-reviews>

Game Recommendations on Steam

<https://www.kaggle.com/datasets/antonkozyriev/game-recommendations-on-steam>

Gold spot prices

<https://www.gold.org/goldhub/data/gold-prices>

Nutritional values for common foods and products

<https://www.kaggle.com/datasets/trolukovich/nutritional-values-for-common-foods-and-products>

Manga & Anime dataset 2024

<https://www.kaggle.com/datasets/duongtruongbinh/manga-and-anime-dataset>

MeteoSchweiz Open Data:

<https://www.meteoschweiz.admin.ch/service-und-publikationen/service/open-data.html>

Music & Mental Health Survey Results

<https://www.kaggle.com/datasets/catherinerasgaitis/mxmh-survey-results>

Open Transport Data Swiss Ist-Daten Archiv:

https://archive.opentransportdata.swiss/actual_data_archive.htm

PEN America's Index of School Book Bans

<https://docs.google.com/spreadsheets/d/1sCpqLprPXHM-Wyt-WYJR30-NvbGLiaVNR8qTsZFG8/edit?gid=0#gid=0>

RecipeNLG (cooking recipes dataset)

<https://www.kaggle.com/datasets/paultimothymooney/recipeNLG>

Spotify One Million Playlists

<https://www.aicrowd.com/challenges/spotify-million-playlist-dataset-challenge>

Spotify One Million Tracks

<https://www.kaggle.com/datasets/amitanshjoshi/spotify-1million-tracks>

Spotify Playlists

<https://www.kaggle.com/datasets/andrewmvd/spotify-playlists>

Steam Games Dataset

<https://www.kaggle.com/datasets/fronkongames/steam-games-dataset>

Streaming Service Price History

<https://www.kaggle.com/datasets/webdevbadger/streaming-service-prices/data>

The GDELT Project

<https://www.gdeltproject.org/data.html>

Top games on Twitch 2016 - 2023

<https://www.kaggle.com/datasets/rankirsh/evolution-of-top-games-on-twitch>

Top Video Games 1995-2021 Metacritic

<https://www.kaggle.com/datasets/deepcontractor/top-video-games-19952021-metacritic>

Video Game Sales with Ratings

<https://www.kaggle.com/datasets/rush4ratio/video-game-sales-with-ratings>

yFinance –Download market data from Yahoo! Finance's API

<https://github.com/ranaroussi/yfinance>

Diese Liste basiert auf vergangenen Studierendenprojekten, die erfolgreich durchgeführt worden sind. Sie ist nicht abschliessend und nicht verbindlich. Sie dürfen gerne Ihre eigenen Datenquellen recherchieren.