

Übung: SQL Performance

1. Lernziele

Sie lernen die folgenden Kompetenzen:

- Verständnis für die Funktionsweise des Query Optimizers
- Analyse von Ausführungsplänen mit EXPLAIN,
- Speichern von Zwischenergebnissen als materialisierte Ansichten mit CREATE TABLE AS SELECT,
- Erstellen von Indizes auf Suchspalten mit CREATE INDEX

2. Buch SQL & NoSQL Datenbanken

- Lesen Sie Kapitel 5.2.1-5.2.2, 5.2.3 und 5.3.1-5.3.4 im Buch von Kaufmann & Meier (2023).
- Beantworten Sie dabei folgende Fragen:

- ? Was ist ein B-Baum, und wozu dient er für die Anfrageoptimierung?
- ? Was ist ein Grid-File, und wozu dient er für die Anfrageoptimierung?
- ? Warum ist ein Join schneller mit Index?
- ? Was ist ein Ausführungsplan, und wie kann man ihn zur Performance-Optimierung anwenden?

B-Baum:

Ein B-Baum ist eine balancierte Indexstruktur, die große Daten effizient speichert und durchsucht. Er optimiert Anfragen, indem er die Anzahl teurer Speicherzugriffe stark reduziert.

Grid-File:

Ein Grid-File ist eine mehrdimensionale Indexstruktur für Zugriffe über mehrere Attribute gleichzeitig. Es beschleunigt komplexe Abfragen, da relevante Daten direkt über ein Verzeichnis gefunden werden.

Join mit Index:

Ein Join ist mit Index schneller, weil passende Datensätze direkt gefunden werden, statt alle Kombinationen zu vergleichen. Dadurch werden Suchaufwand und Laufzeit erheblich reduziert.

Ausführungsplan:

Ein Ausführungsplan beschreibt, wie eine Datenbank eine Anfrage intern ausführt. Er wird zur Optimierung genutzt, indem ineffiziente Schritte erkannt und z. B. durch bessere Indexe oder Join-Reihenfolgen verbessert werden.

3. Wissenschaftliche Literatur

Fassen Sie kurz die Komponenten des Theoriemodells eines Query Optimizers zusammen, wie sie im Paper von Ioannidis (1996) beschrieben sind.

Y. E. Ioannidis, "Query optimization," *ACM Comput. Surv.*, vol. 28, no. 1, pp. 121–123, Mar. 1996, doi: [10.1145/234313.234367](https://doi.org/10.1145/234313.234367).

1. Rewriter (Deklarative Phase)

Transformiert die Anfrage in äquivalente, aber potenziell effizientere Formen (z. B. Flattening, View-Auflösung).

Arbeitet **kostenunabhängig**, nur auf Basis logischer Eigenschaften.

2. Planner (Zentrale Steuerung)

Durchsucht den Raum möglicher Ausführungspläne.

Nutzt Suchstrategien (typisch: dynamische Programmierung).

Wählt den Plan mit minimal geschätzten Kosten.

3. Algebraic Space

Definiert **logische Alternativen** (Operatorreihenfolgen, Join-Reihenfolgen).

Beschränkt den Suchraum durch Heuristiken (z. B. keine unnötigen Kreuzprodukte).

4. Method-Structure Space

Legt **physische Implementierungsalternativen** fest (Join-Algorithmen, Indexnutzung etc.).

Erzeugt konkrete Ausführungspläne aus algebraischen Strukturen.

5. Cost Model

Bewertet Pläne mittels Kostenfunktionen (z. B. I/O, CPU).

Liefert Vergleichsgrundlage für den Planner.

6. Size-Distribution Estimator

Schätzt Zwischenergebnisgrößen und Datenverteilungen.

Liefert essentielle Eingaben für das Kostenmodell (z. B. via Histogramme).

4. SQL Arbeitsbuch: Kapitel 6

- Arbeiten Sie Kapitel 6 durch: Optimieren von Abfragen. Führen Sie die entsprechenden Schritte selbständig an Ihrem Computer durch.
- Lösen Sie die Herausforderungen am Ende des Kapitels:
 - Anstelle der Anzahl der Fünf-Sterne-Bewertungen soll der quadratische Mittelwert der Bewertungen berücksichtigt werden, geteilt durch die Gesamtzahl der Bewertungen, unabhängig von der Anzahl der Sterne.
 - Wie schneidet diese Methode in Bezug auf Geschwindigkeit und Qualität der Empfehlungen ab?

```
SELECT MovieID, Title,  
       AVG(Rating) AS AVR, COUNT(*) AS NR  
FROM Ratings  
JOIN Movies USING (MovieID)  
WHERE UserID IN (  
    SELECT UserId  
    FROM Ratings5MI  
    WHERE MovieID = 1371 )  
GROUP BY MovieID  
HAVING COUNT(*) > 100  
ORDER BY (AVR)/NR DESC  
LIMIT 10;
```

Schlecht UND langsamer trotz Index & MV

5. Semesterprojekt

- Diese Woche werden Sie die Datenbankabfrage für Ihr Semesterprojekt optimieren.
- Mit welchen Methoden konnten Sie die Geschwindigkeit der Abfragen optimieren?
- Wie lange dauern die Abfragen mit und ohne Optimierung?

6. Diskussion der Übung und Präsentation

Ein Team wird den Stand des Projekts bis und mit Optimierung der Klasse präsentieren.