

Übung: Big Data und NoSQL Datenbanken

1. Lernziele

- Die globale Datenexplosion kontextualisieren
- Aufzeigen, was Big Data wirklich bedeutet
- Argumentieren, wie NoSQL-Datenbanken die Verwaltung von Big Data unterstützen können
- Ein NoSQL-Datenbanksystem in der Cloud aufsetzen: MongoDB Atlas
- Werkzeuge für Big Data installieren: MongoDB Shell, MongoDB Database Tools, PowerShell

2. Buch SQL & NoSQL Datenbanken

- Lesen Sie Kapitel 1.3-1-5 7 im Buch von Kaufmann & Meier (2023). Sie finden den Link auf ILIAS.
- ? Was heisst Schemafreiheit, und wie hilft es, Big Data zu managen?
- ? Was heisst indexfreie Nachbarschaft, und wie unterstützt es das Big Data Management?
- ? Was ist ein Dokument, und wieso ist diese Datenstruktur für Big Data geeignet?

3. Fallbeispiel Decathlon mit MongoDB

Lesen Sie die Fallstudie Decathlon mit MongoDB:

<https://www.mongodb.com/solutions/customer-case-studies/decathlon>

- ? Welche Big-Data-Aspekte sind involviert?

Its SQL-based system couldn't handle the massive influx of requests—ranging from hundreds to thousands per second—during peak times. => velocity

"We needed horizontal scalability for growing volumes," => volume

" MongoDB's document-based model could also manage diverse data formats like text, images, and videos, essential for modern user-generated content. " => Variety

- ? Warum kam die SQL-Technologie an ihre Grenzen?

"challenges, particularly in managing the synchronization between SQL and Elasticsearch"

- ? Wie hat die Dokument-Datenbank das Problem gelöst?

To achieve scalability, MongoDB uses sharding to distribute data across multiple servers. A dedicated analytics node aggregates data from all shards, enabling efficient cross-region queries without slowing performance. => Effective and efficient Sharding of documents

4. Wissenschaftliche Literatur: Globale Datenexplosion

- Schauen Sie den Science-Artikel von Hilbert et al. (2011) an: The World's Technological Capacity to Store, Communicate, and Compute Information.
- ? Wie hat sich die potenzielle Informationsmenge weltweit entwickelt?
Die Informationsmenge entwickelt sich exponentiell => sie beschreibt ein Wachstum $y = a^x$
Die geschätzte Wachstumsrate ist 23% pro Jahr
Dies bedeutet eine Verdopplung aller 31/3 Jahre:
 $1.23^y = 2 \Leftrightarrow y = \ln(2) / \ln(1.23) = 3.348307909$.
Test: $1.23 \text{ hoch } 3.348307909 = 2$
- ? Wieviel Speicherkapazität wurde fürs Jahr 2007 geschätzt? Wo stehen wir heute, wenn wir diesen Trend extrapolieren? Tipp: Benutzen Sie eine Exponentialgleichung. Sie können diese mit Wolfram Alpha lösen lassen.
Nach (Hilbert & López, 2011) wurde 2007 die globale Informationskapazität auf $2,9 \times 10^{20}$ Bytes geschätzt. Dies entspricht 290 Exabytes (EB) oder 290 Millionen Terabytes
2017: $290\text{EB} \cdot 1.23^{10} = \text{ca. } 2.3 \text{ Zettabytes}$ (den Begriff gibt es erst seit 1991) oder 2.19 Mia. TB
2020: $290\text{EB} \cdot 1.23^{13} = \text{ca. } 4.28 \text{ Zettabytes (ZB)}$
2030: $290\text{EB} \cdot 1.23^{23} = \text{ca. } 35.6 \text{ ZB}$
1 ZB = 1'000'000'000'000'000'000 Bytes
Die Yottabyte-Grenze wird 2046 geknackt (1 YB = 1000'000 EB = 1'000'000'000'000 TB)
https://en.wikipedia.org/wiki/Metric_prefix
- ? Wenn dieser Trend so weitergeht, in welchem Jahr ist der gesamte Planet Erde ein einziges Datenrechenzentrum? Nehmen wir an, man könnte realistisch maximal 10^{38} Byte mit der verfügbaren Masse und verfügbaren Energie auf der Erde speichern und betreiben, inkl. Verarbeitung und Kühlung¹.
 $10^{20} \cdot 1.23^y = 10^{38}$
https://www.wolframalpha.com/input?i=10%5E20*1.23%5Ey+%3D10%5E46
Wir haben noch etwa 200 Jahre.
- ? Was bedeutet dies für unsere Gesellschaft, für Organisationen und für einzelne Menschen?
Die Datenüberflutung wird grösser, es wird immer wichtiger, die richtigen Daten auszuwählen und gezielt zu nutzen, sowohl für Einzelne (Job, Wohnung, Partnerschaft, Informationen, Soziale Netzwerke, Autokauf, Online Shopping, aber auch Lifestyle-Entscheidungen wie Ernährung, impfen usw. usw.) als auch für Organisationen, welche immer stärker ihre Daten filtern und für Entscheidungsfindung nutzen müssen, um konkurrenzfähig zu bleiben.
Weiterhin sinkt die Entropie weltweit. Daten bedeuten letztlich auch Information, d.h. Senkung von Unsicherheiten bzw. Entropie. Es wird also eher mehr Struktur durch Daten generiert werden.
Zudem: das Datenwachstum kann nicht ewig so weitergehen. Irgendwann braucht es eine Sättigung.
=> Nachhaltiges Datenmanagement

5. MongoDB Workbook Kapitel 1 & 2: Überblick und Installation

- Auf ILIAS finden Sie zwei Kapitel des MongoDB-Arbeitsbuchs, das Ihnen Schritt für Schritt bei der Erstellung einer NoSQL-Datenbankanwendung helfen wird.
 - Lesen Sie Kapitel 1: "Plan your MongoDB Database System".
 - Arbeiten Sie Kapitel 2 durch: "Installation of Database Tools and Software". Führen Sie die entsprechenden Schritte selbstständig auf Ihrem Computer durch, um die gesamte erforderliche Software für das MongoDB-Projekt zu installieren.

¹ <https://chatgpt.com/share/68bea720-8aa0-8013-8d5c-3939d16e904a>

6. Semesterprojekt

- Diese Woche analysieren Sie Big Data Aspekte Ihres Projekts.
- ? Was ist Ihr Use Case?
- ? Wie generieren Sie Wert mit Daten?
- ? Welche Aspekte von Big Data bezüglich Volume, Variety, Velocity, Variability, Veracity, Value (siehe Folie 12) haben Sie zu bewältigen?
- ? Wie gehen Sie diese an?

7. Projektpräsentation

- Ein Team wird in der nächsten Sitzung den Status ihres Projekts bis und mit dem Thema Big Data & NoSQL Datenbanken vorstellen.