

Übung: Datenbank-Integration (NoSQL)

1. Lernziele

Sie lernen die folgenden Kompetenzen:

1. Überblick auf die allgemeinen Aufgaben der Big Data Integration
2. Daten zur Optimierung der Speicherung für die Verarbeitungsgeschwindigkeit mit PowerShell vorverarbeiten
3. Daten mit Mongoimport in den Atlas Cloud-Datenbankcluster zu laden
4. Daten auf dem Datenbankserver mithilfe von MongoDB Query Language (MQL)-Anweisungen zu transformieren:
 - Daten anzeigen mit `find()`, `findOne()`
 - Aggregation Pipelines mit `aggregate()`
 - Felder hinzufügen und manipulieren mit `$addField` und `$merge`
 - Arraywerte extrahieren mit `$split` und `$arrayElemAt`
 - Textteile extrahieren mit `$regexFind`
 - Feldstruktur ändern mit `$project` und `$out`
 - Kollektionen löschen mit `drop()`
 - Duplikate entfernen mit `$group`
 - Indexe erstellen mit `createIndex()`
 - Kollektionen verknüpfen mit `$lookup`
 - Feldstruktur ändern mit `$replaceWith` und `$out`
 - Felder umbenennen mit `updateMany()` und `$rename`
 - Felder löschen mit `updateMany()` und `$unset`
 - Felder in verschachtelten Arrays ändern mit `$map`

2. Lernvideos (optional)

- Schauen Sie sich dieses Video an: «Import Data into MongoDB 3 Ways»
 - <https://www.youtube.com/watch?v=N6DC0uQ6c-k>
- Auch dieses Video könnte interessant sein: «Data Pipelines Explained»
 - <https://www.youtube.com/watch?v=6kEGUCrBEU0>

3. Wissenschaftliche Literatur: Big Data Integration

- ? Welche verschiedenen Aufgaben erkennen Sie für die drei Phasen Extract, Transform und Load anhand des Papers (vgl. ILIAS) von Bansal & Kagemann 2015?
- ? Welche dieser Aufgaben fallen in Ihrem Projekt an, und wie genau?

4. MongoDB-Arbeitsbuch Kapitel 4: Preprocess, Load and Transform Data

- Arbeiten Sie das Kapitel 4 des MongoDB Arbeitsbuchs (vgl. ILIAS) selbstständig durch.
- ? Wie lange dauert es, die Datei "ratings.csv" mit PowerShell auf fünf-Sterne-Bewertungen zu filtern?
- ? Wie lange dauert es, die fünf-Sterne-Bewertungen in den MongoDB-Cluster auf Atlas zu laden?

- Lösen Sie die Übung am Ende des Kapitels (Abschn. 4.6).
- ? Aggregation aller Filmdaten in einem einzigen Dokumenttyp: Nehmen wir an, Sie möchten die Daten aus den beiden CSV-Dateien in einem einzigen aggregierten Dokumenttyp zusammenführen, der für jeden Benutzer alle Bewertungen einschließlich der Filmdetails (Titel, Jahr, Genre) enthält.
- ? Am Ende von Kapitel 3 haben Sie die Dokumentenstruktur dafür bereits modelliert. Wie sieht der MQL-Code aus, um die Daten in dieses Format umzuwandeln?
- ? Tipp: verwende `createIndex()` und `$Lookup` für Movies, wie im Skript für die Integration von Ratings zu Users gezeigt.
- Zeigen Sie eine live Demo des Codes, indem Sie ihn auf deiner MongoDB Atlas Cloud auf den MovieLens-Daten ausführen, sodass das Resultat der Lösung der Aufgabe entspricht.

5. Semesterprojekt

- Erklären Sie den aktuellen Status Ihres Projekts.
- Beschreiben Sie, wie ihr Team Daten in die MongoDB-Datenbank geladen und transformiert hat.
- ? Über welche Datenquellen verfügen Sie?
- ? Wie sehen die Rohdateien aus?
- ? Welche Zieldatenbankstruktur benötigen Sie für die Analyse?
- ? Wie laden Sie die Daten in die Datenbank mit Mongoimport?
- ? Wie transformieren Sie die Daten in die Zielstruktur mit MQL?

6. Diskussion der Übung und Präsentation

- Ein Team wird seine Ergebnisse dieser Übung der Klasse präsentieren.
- Bitte zeigt die Übung, den Stand Ihres Projekts sowie einen Einblick in den Projektbericht.